

2. Számítógépes számábrázolás és kerekítés

A programozási nyelvek és a hardver a nagyobb hatékonyság kedvéért **véges, rögzített hosszúságú** számábrázolást alkalmaznak. Két leggyakoribb formátum a decimális egész ($\pm\text{xxxxx}$) és a decimális lebegőpontos szám ($\pm\text{xxxxx}\cdot 10^{\pm\text{xxx}}$). A véges ábrázolás az oka annak, hogy a gépi számítás eredménye rendszerint csak közelítés.

Egész számok ábrázolása

Az egész számokat fix hosszúságú bitsorozat tárolja, az előjelet általában **kettes komplement** alakban kezelve (a legmagasabb helyiértékű bit az előjel). Az egész számok jellemzően 2 vagy 4 bájt hosszúak, így a tárolható legnagyobb (előjel nélküli) érték 2^{15} , illetve 2^{31} körüli.

Az egész számokkal általában kevesebb numerikus probléma van, de gondot okozhat a **túlcsordulás**: ha egy számláló értéke meghaladná a legnagyobb ábrázolható, „átfordulhat” negatívba (klasszikus példa a Tetris pontszáma). Sok feladatban épp ezért fontos, hogy csak egész értékek jöhessenek szóba — például banki műveletek számításakor.

Lebegőpontos számok ábrázolása

A lebegőpontos szám az exponens előtti **mantisszából** és egy **exponensből** áll. Egy gyakori alak az, amelyben a mantissza első (tizedespont utáni) jegye nem nulla — ezt nevezzük **normalizált** alaknak. Kis abszolút értékű számoknak nincs mindig normalizált alakjuk (ilyen maga a nulla is); ezeket **denormalizáltak** hívjuk. Az általánosított normalizált lebegőpontos szám tehát egy L jegyű mantisszából és egy $[-E, F]$ intervallumba eső exponensből áll, az alap (bázis) pedig rendszerint 2 hatványa:

$$x = (-1)^s \cdot m \cdot B^e, \quad B = 2$$

ahol s az előjel, m a mantissza, e az exponens. A PC-k az **IEEE 754** bináris lebegőpontos szabványt követik:

- **Szimpla pontosság** (real*4): 24 bites mantissza, 8 bites exponens; a normalizált abszolút értékek kb. 10^{-38} és 10^{+38} között, ami kb. **7 értékes tizedesjegy**.
- **Dupla pontosság** (real*8): $L = 52$, $E = 1022 = F - 1$; a normalizált abszolút értékek kb. 10^{-308} és 10^{+308} között, ami kb. **16 értékes tizedesjegy**.

A MATLAB belső ábrázolása dupla pontosságú, ezért a szimpla pontosság vele nem is illusztrálható; az egész, valós és komplex számok között bizonyos értelemben nem tesz különbséget. Megjegyzendő, hogy ezek a formátumok a *tárolt* számokra vonatkoznak — a processzoron belüli formátumok rendszerint pontosabbak.

Kerekítés

A kerekítés arra szolgál, hogy a ténylegesen ábrázolható számok (a **gépi számok**) közül kiválasszuk azt, amellyel az eredményünket azonosítjuk.

- **Optimális kerekítés**: a számhoz legközelebbi gépi számot adja.
- **Levágás (csonkolás)**: egyszerűen elhagyja a jegyek egy részét (ha L jegyre kerekítünk, az L -edik utániakat). Könnyebb megvalósítani, de pontatlanabb.

Egy kerekítést **korrektnek** nevezünk, ha a szám és a kerekített értéke között nincs gépi szám; az optimális kerekítés és a levágás is korrekt.

Példa: a $\pi = 3,14159265\dots$ négy jegyre vett optimális kerekítése 3,142, levágással kapott kerekítése pedig 3,141.

Gépi pontosság (gépi epszilon)

A kerekítés relatív pontosságát a **gépi epszilon** jellemzi: a legkisebb olyan pozitív szám, amelyet 1-hez adva 1-nél nagyobb gépi számot kapunk. Korlátlan exponenshosszt és nem nulla értéket feltételezve a B bázisú, L jegyre való kerekítés relatív pontossága:

$$\varepsilon = B^{1-L} \qquad \varepsilon = \frac{1}{2} B^{1-L}$$

A bal oldali képlet a **korrekt**, a jobb oldali az **optimális** kerekítés relatív pontossága. Az állítás (pozitív, normalizált $x = .x_1x_2\dots x_L\dots \cdot B^e$, $x_1 \neq 0$ esetén) abból következik, hogy a korrekt kerekítés eltérése legfeljebb az L . pozíción vett egy egység, azaz B^{e-L} :

$$|x - \tilde{x}| \leq B^{e-L} = B^{e-1} B^{1-L} \leq |x| B^{1-L}.$$

Felül- és alulcsordulás

Mivel az exponens hossza a gyakorlatban véges, az ábrázolandó szám lehet túl nagy (**felülcsordulás**) vagy túl kicsi (**alulcsordulás**) a normalizált ábrázoláshoz. Alulcsordulásakor denormalizált eredmény keletkezhet, ami ronthatja a relatív pontosságot; ezen a nagyságrendek megváltoztatása, az ún. **skálázás** segíthet. A kerekítési módok (köztük a kifelé kerekítés) az IEEE 754 szabvány részei.