

17. Konjugált gradiens módszer

A konjugált gradiens (Conjugate Gradient, CG) módszer **szimmetrikus, pozitív definit** mátrixú lineáris rendszerek iteratív megoldására szolgál. Pontos aritmetikával véges sok (legfeljebb n) lépésben megtalálná a megoldást, de a kerekítési hibák miatt iterációként kezeljük. Nagy, ritka rendszerekre kiválóan alkalmas.

$$Ax = b,$$

A megoldandó rendszer (A szimmetrikus, pozitív definit)

Alapötlet: optimalizálás

A megoldást egy kvadratikus függvény minimumaként fogjuk fel:

$$q(x) = \frac{1}{2}x^T Ax - x^T b.$$

$$f(x) = \frac{1}{2}x^T Ax - b^T x.$$

A kvadratikus célfüggvény

Mivel A pozitív definit, q paraboloid, amelynek egyetlen minimuma épp az $Ax^* = b$ megoldás. Két kulcsészrevétel:

- A negatív gradiens a **reziduum**: $-\nabla q(x) = b - Ax = r$.
- Adott s_k keresési irány mentén az optimális lépéshossz **zárt alakban** adódik (ott, ahol az új reziduum merőleges s_k -ra).

Konjugált irányok

A megoldást nem tetszőleges, hanem egymásra **A-konjugált** irányok mentén keressük ($p_i^T A p_j = 0$, ha $i \neq j$):

$$p_i^T A p_j = 0, \quad \forall i \neq j.$$

Az irányok A-konjugáltsága

Az algoritmus

Induljunk az x_0 pontból, legyen $s_0 = r_0 = b - Ax_0$, majd ismételjük:

$$\alpha_k = \frac{r_k^T r_k}{s_k^T A s_k}, \quad x_{k+1} = x_k + \alpha_k s_k, \quad r_{k+1} = r_k - \alpha_k A s_k$$

$$\beta_{k+1} = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}, \quad s_{k+1} = r_{k+1} + \beta_{k+1} s_k$$

$$r^{(0)} = b - Ax^{(0)}.$$

A kezdeti reziduum

$$p^{(0)} = r^{(0)}.$$

A kezdeti irány

$$\alpha_k = \frac{(r^{(k)})^T r^{(k)}}{(p^{(k)})^T A p^{(k)}}.$$

A lépéshossz

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}.$$

Az új közelítés

$$r^{(k+1)} = r^{(k)} - \alpha_k A p^{(k)}.$$

Az új reziduum

$$\beta_k = \frac{(r^{(k+1)})^T r^{(k+1)}}{(r^{(k)})^T r^{(k)}}.$$

A β együttható

$$p^{(k+1)} = r^{(k+1)} + \beta_k p^{(k)}.$$

Az új keresési irány

Az iterációt addig folytatjuk, amíg a reziduum normája elég kicsi:

$$\|r^{(k+1)}\| < \epsilon.$$

Megállási feltétel

A módszer neve onnan ered, hogy a sima gradiensmódszer „völgyszerű” függvényeknél feleslegesen sokat cikázik; a CG a lépésenkénti konjugált irányváltással ezt kiküszöböli, és a hibát minden lépésben egy újabb A -ortogonális irányban tünteti el.

Kidolgozott példa

$$\begin{aligned} 4x_1 + x_2 &= 15, \\ x_1 + 3x_2 &= 10. \end{aligned}$$

A rendszer

$$A = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix}, \quad b = \begin{bmatrix} 15 \\ 10 \end{bmatrix}.$$

A mátrixok

$$\mathbf{x}^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)} = \begin{bmatrix} 15 \\ 10 \end{bmatrix}.$$

Induló értékek

$$\alpha_0 = \frac{(\mathbf{r}^{(0)})^T \mathbf{r}^{(0)}}{(\mathbf{p}^{(0)})^T \mathbf{A} \mathbf{p}^{(0)}} = \frac{15^2 + 10^2}{15 \cdot (4 \cdot 15 + 10) + 10 \cdot (15 + 30)} = 0.27.$$

A lépéshossz

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \alpha_0 \mathbf{p}^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + 0.27 \cdot \begin{bmatrix} 15 \\ 10 \end{bmatrix} = \begin{bmatrix} 4.05 \\ 2.7 \end{bmatrix}.$$

Az új közelítés

Az iterációkat folytatva a megoldás (legfeljebb n lépésben) konvergál:

$$\mathbf{x} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}.$$

A megoldás

Előnyök és hátrányok

- **Előny:** nagy, ritka SPD rendszerekre nagyon hatékony; gyorsabb a Jacobi/Gauss–Seidel módszereknél; elvileg $\leq n$ lépésben pontos.
- **Hátrány:** csak szimmetrikus, pozitív definit mátrixra; a kerekítési hibák ronthatják a pontosságot (a gyakorlatban előkondicionálással, pcg-vel javítható).